

Auditoria tecnica dos resultados finais do TP2

Data da auditoria: 2026-06-11.

Escopo: codigo local, outputs/, outputs/diagnostics/ e especificacao do TP2 em PDF.

Restricao respeitada: nao rodei treino nem inferencia; usei apenas leitura leve de JSON/JSONL e inspecao de codigo.

Veredito

A conclusao central e metodologicamente defensavel, com uma formulacao cuidadosa:

O LoRA em Qwen2.5-3B melhora Spider de 59,57% para ate 66,83% no melhor checkpoint observado, enquanto o MMLU cai de 57,33% para 55,33% na suite de 150 questoes.

Essa frase e defensavel porque os numeros foram recomputados dos JSONL, a avaliacao Spider e pareada, o ganho Spider e estatisticamente forte contra o baseline, e a queda MMLU observada e pequena e nao significativa na suite usada.

Ressalva importante: 66,83% nao e o Exp C final; e o Exp C checkpoint-875. O Exp C final obteve 64,70%. Portanto, no relatorio, a frase deve dizer “melhor checkpoint observado” ou “checkpoint-875/early stopping”. Se o texto apresentar 66,83% como resultado final do Exp C sem essa ressalva, fica metodologicamente impreciso. Se quiser uma afirmacao mais conservadora e preregistrada, use Exp B = 66,34%.

Critérios da especificacao usados como fonte de rigor

A especificacao exige: Spider train exclusivo para fine-tuning; Spider dev para avaliacao; Execution Accuracy por execucao SQLite como metrica unica de Text-to-SQL; prompt com schema do banco; MMLU com exatamente 150 questoes, 50 por cada uma de 3 categorias; MMLU em 5-shot; LoRA documentado com r, alpha, dropout e target_modules; pelo menos duas configuracoes de hiperparametros; sementes fixadas e geracao deterministica.

Auditoria de codigo

Area	Evidencia local	Veredito
Treinamento	src/training.py fixa seed,	Aderente ao desenho do

Area	Evidencia local	Veredito
	carrega Spider train, formata prompt + completion, usa completion_only_loss, adiciona o EOS de chat do Qwen, cria SFTTrainer com LoRA e salva adapter/tokenizer/logs.	TP2.
LoRA	src/model.py cria LoraConfig com r, lora_alpha, lora_dropout, target_modules; load_for_inference usa PeftModel.from_pretrained quando encontra adapter_config.json.	Carregamento LoRA correto para outputs/<exp>/adapter e checkpoints.
Spider	src/evaluation.py carrega Spider dev, usa Spider train para 3-shot, aplica o mesmo prompt, salva raw_output, predicted_sql, score e erros.	Comparabilidade adequada entre baseline e LoRA.
Execution Accuracy	custom_metrics/execution_accuracy.py extrai SQL, bloqueia SQL destrutivo, executa predicted/gold em SQLite read-only, ignora ordem salvo ORDER BY.	Atende ao nucleo exigido. Nao e o avaliador oficial completo do Spider, mas a especificacao permite metrica customizada por execucao.
MMLU	src/evaluation.py carrega suite persistida, usa 5-shot por subcategoria, greedy/temperature 0, parseia A/B/C/D e salva JSONL.	Aderente; todos os 150 outputs foram parseados.
Reprodutibilidade	configs usam seed 42, temperature: 0.0,	Bom. Caveat: data/processed/ nao esta

Area	Evidencia local	Veredito
	do_sample: false, ambiente registra GPU L4 e versoes.	presente neste workspace, entao nao consegui verificar diretamente a suite MMLU persistida nem os splits Spider, apenas os outputs.

Metricas recomputadas

Modelo	Spider	Spider acc	MMLU	MMLU acc	Delta Spider vs base	Delta MMLU vs base
Base	616/1034	59,57%	86/150	57,33%	0,00 pp	0,00 pp
Exp A	674/1034	65,18%	82/150	54,67%	+5,61 pp	-2,67 pp
Exp B	686/1034	66,34%	83/150	55,33%	+6,77 pp	-2,00 pp
Exp C final	669/1034	64,70%	83/150	55,33%	+5,13 pp	-2,00 pp
Exp C checkpoint-875	691/1034	66,83%	83/150	55,33%	+7,25 pp	-2,00 pp

Todos os totais esperados foram confirmados a partir dos JSONL.

MMLU por categoria

Modelo	STEM	Humanidades	Sociais
Base	32/50	28/50	26/50
Exp A	30/50	27/50	25/50
Exp B	31/50	26/50	26/50
Exp C final	29/50	28/50	26/50
Exp C checkpoint-875	29/50	28/50	26/50

A queda MMLU de 86 para 83 acertos e pequena em valor observado, mas a suite tem apenas 150 itens. IC Wilson 95% aproximado: Base 49,33%-64,97%; Exp B/Exp C 47,34%-63,06%. Os intervalos se sobrepõem muito. O resultado permite dizer

“nao houve evidencia de degradacao grande nesta suite”, mas nao prova preservacao geral de capacidade.

McNemar pareado em Spider

Teste exato bicaudal de McNemar, pareado por example_id.

Comparacao	Modelo 1 correto / Modelo 2 errado	Modelo 1 errado / Modelo 2 correto	Delta do Modelo 2	p exato
Base vs Exp A	73	131	+5,61 pp	5,92e-05
Base vs Exp B	73	143	+6,77 pp	2,20e-06
Base vs Exp C final	83	136	+5,13 pp	4,17e-04
Base vs Exp C checkpoint -875	62	137	+7,25 pp	1,11e-07
Exp C final vs checkpoint -875	45	67	+2,13 pp para checkpoint	0,0467

O ganho Spider de LoRA contra baseline e robusto para todos os experimentos. A superioridade do checkpoint-875 sobre o Exp C final e menor, mas aparece no limiar de significancia.

McNemar pareado em MMLU

Comparacao	Base correto / modelo errado	Base errado / modelo correto	Delta	p exato
Base vs Exp A	4	0	-2,67 pp	0,125
Base vs Exp B	4	1	-2,00 pp	0,375
Base vs	6	3	-2,00 pp	0,508

Comparacao	Base correto / modelo errado	Base errado / modelo correto	Delta	p exato
Exp C final				
Base vs checkpoint -875	6	3	-2,00 pp	0,508

Nao ha evidencia estatistica forte de regressao MMLU nesta suite. Isso ajuda a explicar por que a degradacao baixa nao e automaticamente suspeita: a intervencao LoRA e pequena e a avaliacao MMLU e curta.

Por que Exp C final e pior que checkpoint-875

O Exp C final treinou 2 epocas com q/k/v/o, enquanto o checkpoint-875 e o ponto de 1 epoca dentro da execucao de 2 epocas. O treino continuou reduzindo loss, mas Spider dev piorou:

Artefato	Passos	Epoca	Train loss reportado	Spider
Exp C checkpoint -875	875	1,0	intermediario, LR ainda ~5,19e-5 no fim da epoca	691/1034
Exp C final/check point-1750	1750	2,0	0,1669 agregado; logs finais com loss ~0,07-0,10	669/1034

Isso e compativel com sobreajuste ou com mudanca indesejada de comportamento gerativo. O principal sinal concreto e o aumento de saidas vazias/sem SQL no Exp C final:

Modelo	raw_output vazio	predicted_sql vazio	sql_extraction_error
Exp B	4	5	5
Exp C final	50	53	53
Exp C final sem stop	50	53	53
Exp C checkpoint-87	1	2	2

Modelo	raw_output vazio	predicted_sql vazio	sql_extraction_error
5 sem stop			

Na comparacao checkpoint-875 vs Exp C final, o checkpoint acerta 67 exemplos que o final erra; em 26 desses, o erro do final e sql_extraction_error. O final acerta 45 que o checkpoint erra. Logo, a diferenca liquida de 22 acertos vem em boa parte de falhas de geracao/extração no final.

Stop sequences

As stop_sequences foram refutadas como causa da queda do Exp C final:

Comparacao	Score diff	Raw output diff	Predicted SQL diff	Resultado
Exp C final normal vs Exp C final sem stop	0/1034	0/1034	0/1034	Identico

Se as stop sequences estivessem cortando respostas validas, a avaliacao sem stop deveria produzir raw_output ou score diferente. Nao produziu.

Hipotese de early EOS no Exp C final

A hipotese de early EOS e plausivel, mas nao provada conclusivamente pelos artefatos atuais.

Evidencias a favor:

- Exp C final sem stop preserva 50 raw_output vazios, portanto nao e truncamento por stop sequence.
- O checkpoint-875 do mesmo experimento tem apenas 1 raw_output vazio.
- A rotina de inferencia decodifica com skip_special_tokens=True; uma geracao que emite imediatamente <|im_end|> pode virar string vazia nos JSONL.
- O treinamento adiciona <|im_end|> ao fim das completions e a segunda epoca pode ter reforcado demais a probabilidade de parar cedo.

Limite da evidencia:

- Os JSONL nao salvam ids de tokens gerados, token bruto com skip_special_tokens=False, eos_token_id emitido, nem motivo de parada. Entao

nao da para provar que o primeiro token foi EOS sem reexecutar inferencia instrumentada.

Conclusao: early EOS e a melhor explicacao local para parte da queda do Exp C final, mas deve ser escrito como “forte indicio”, nao como fato fechado.

Analise dos hiperparametros

Fator	Evidencia	Interpretacao
q/v vs q/k/v/o	Exp A 65,18%; Exp B 66,34%.	Expandir target modules melhorou Spider em +1,16 pp sem piorar MMLU alem de 1 item em relacao ao A.
1 vs 2 epocas	Exp B 66,34%; Exp C final 64,70%; C checkpoint-875 66,83%.	Segunda epoca nao ajudou; usar checkpoint intermediario e melhor.
LR 1e-4	Todos os experimentos finais usam 1e-4.	Conservador o suficiente para nao gerar queda MMLU grande; ainda assim 2 epocas geraram falhas de parada.
r=16, alpha=32	Confirmado nos adapters.	Configuracao PEFT moderada; coerente com ganho sem grande regressao geral.
dropout=0.05	Confirmado nos adapters.	Regularizacao leve; nao impediu a degradacao do Exp C final na segunda epoca.
Batch efetivo 8	per_device_train_batch_size=2, gradient_accumulation_steps=4.	Conservador para L4 e coerente com estabilidade.
max_seq_length=2048	Confirmado nos configs.	Suficiente para schema + pergunta; risco de truncamento de treino existe apenas se exemplos muito longos,

Fator	Evidencia	Interpretacao
		mas nao ha evidencia nos outputs de que esse seja o erro dominante.
completion_only_loss=true	Confirmado em config/codigo.	Ajuda a especializar a SQL sem treinar o modelo a copiar prompt; tambem reduz risco de degradacao geral.

Sobre a duvida “o treinamento foi conservador?”: sim para A/B e para o checkpoint-875. O conjunto LoRA, LR 1e-4, batch efetivo 8, uma epoca, dropout 0,05 e loss apenas na completion e conservador o bastante para preservar MMLU na suite curta. O Exp C final mostra o limite: a segunda epoca deixou de ser conservadora para Spider, mesmo sem grande mudanca no MMLU.

Hipoteses plausiveis refutadas pelos resultados

Hipoteses	Status	Evidencia
O ganho Spider e artefato de prompt diferente entre modelos.	Refutada.	prompt_hash bate em 1034/1034 exemplos entre base e LoRA.
Stop sequences explicam a queda do Exp C final.	Refutada.	Avaliacao com e sem stop gerou outputs e scores identicos.
O carregamento LoRA falhou e avaliou modelo base por engano.	Refutada.	Adapters tem configs corretos; resultados diferem do baseline; checkpoints sao carregaveis por adapter_config.json.
MMLU caiu por erro de parsing.	Refutada.	150/150 respostas foram parseadas em todos os modelos.
A segunda epoca necessariamente melhora Spider.	Refutada.	Checkpoint-875 supera o final de 2 epocas.
O target q/v ja captura	Refutada.	q/k/v/o melhora de

Hipotese	Status	Evidencia
todo o ganho possivel.		65,18% para 66,34%/66,83%.
Houve esquecimento catastrofico claro em MMLU.	Refutada nesta suite.	Queda de 2 pp, McNemar nao significativo, categorias sem colapso.
O checkpoint-875 e pior no MMLU que o final.	Refutada.	Ambos fazem 83/150 com mesmas categorias; predicoes MMLU de Exp C final e checkpoint-875 tem 0 discordancias.

Ressalvas metodologicas

1. 66,83% e resultado de checkpoint intermediario. Deve ser tratado como melhor checkpoint observado ou early stopping, nao como resultado final bruto do Exp C.
2. Spider dev foi usado para comparar e escolher modelos/checkpoints. Isso e aceitavel para o TP2 se reportado de forma transparente, mas nao e uma estimativa imparcial de desempenho futuro apos selecao.
3. data/processed/ nao esta presente no workspace auditado. Portanto, confirmei os totais e categorias pelos outputs, mas nao revalidei diretamente a construcao da suite MMLU ou a separacao fisica dos splits.
4. A metrica implementada e Execution Accuracy por execucao SQLite, como exigido, mas nao replica integralmente todos os detalhes do avaliador oficial Spider test-suite.
5. MMLU com 150 questoes e pequeno. A frase correta e “queda observada pequena nesta suite”, nao “o modelo preserva conhecimento geral de modo amplo”.
6. A especificacao pede discutir contaminacao de dados. Os artefatos nao conseguem provar ausencia de contaminacao de Spider/MMLU no pre-treino do Qwen; isso deve ser assumido como limitacao interpretativa.

Recomendacoes para o relatorio

- Reporte a tabela completa: Base, Exp A, Exp B, Exp C final e Exp C checkpoint-875.
- Use o headline: “melhor checkpoint observado: 66,83% Spider; Exp B planejado: 66,34%; Exp C final: 64,70%”.

- Inclua o teste de McNemar para Spider, principalmente Base vs checkpoint-875 ($p=1,11e-07$) e Base vs Exp B ($p=2,20e-06$).
- Para MMLU, diga que a queda de 57,33% para 55,33% equivale a 3 questões e não é estatisticamente forte na suíte de 150 itens.
- Explique o Exp C final como evidência contra “mais épocas sempre ajudam”: houve menor train loss, mas pior Spider dev e 50 saídas vazias.
- Diga explicitamente que stop sequences foram testadas e refutadas como causa.
- Descreva early EOS como hipótese mais provável, com a limitação de que os JSONL não salvam tokens brutos.
- Se houver tempo para uma revisão futura, adicione validação separada para escolher checkpoint, salve tokens gerados com `skip_special_tokens=False`, e reporte motivo de parada/EOS.

Conclusão final

Não encontrei erro crítico que invalide a conclusão de que LoRA melhora Spider com pequena queda observada em MMLU. O resultado é defensável, mas o texto precisa separar três afirmações:

1. Resultado planejado forte: Exp B melhora Spider de 59,57% para 66,34% com MMLU 55,33%.
2. Melhor resultado observado: Exp C checkpoint-875 chega a 66,83% com MMLU 55,33%.
3. Resultado final de 2 épocas: Exp C final cai para 64,70%, provavelmente por sobre-treinamento/early EOS parcial.

Com essas ressalvas, a narrativa técnica fica consistente com a especificação e com os artefatos locais.