

Análise Quantitativa do Trade-off entre Especialização e Generalização em LLMs via Fine-Tuning Text-to-SQL

Matheus - TP2 NLP / Text-to-SQL

Universidade Federal do Amazonas - ICC220 / PPGINF528 - 2026/01

Resumo. Este trabalho implementa e avalia um pipeline reproduzível de fine-tuning supervisionado para Text-to-SQL usando o modelo Qwen/Qwen2.5-3B-Instruct, Spider como tarefa-alvo e MMLU como medida auxiliar de regressão de capacidade geral. O modelo base obteve 59,57% de Execution Accuracy no Spider dev e 57,33% no MMLU 150. Todos os adapters LoRA melhoraram Spider, com ganhos entre +6,58 e +9,19 pontos percentuais. O melhor resultado bruto de Spider foi o Exp G, com 68,76%. O melhor compromisso foi o Exp F, com 68,18% no Spider e a mesma acurácia MMLU da base. A análise mostra ganho real de especialização, regressão geral pequena e diferenças internas entre hiperparâmetros menores que o ganho contra a base.

Palavras-chave. Text-to-SQL, Spider, MMLU, LoRA, Execution Accuracy, Qwen, fine-tuning.

1. INTRODUÇÃO

O objetivo do TP é medir empiricamente o trade-off entre especialização e generalização em um LLM. A especialização foi medida por Text-to-SQL no Spider: dado um esquema de banco, uma pergunta em linguagem natural e exemplos few-shot, o modelo deve gerar uma consulta SQL executável. A generalização foi medida por uma suíte fixa de 150 questões MMLU, com 50 questões de STEM, 50 de Humanidades e 50 de Ciências Sociais.

A pergunta central é se o ganho em Text-to-SQL compensa uma possível perda em tarefas gerais. Para isso, o mesmo pipeline de avaliação foi aplicado ao modelo base e a todos os modelos fine-tuned. A conclusão é limitada ao modelo, aos dados, aos prompts, à seed e aos hiperparâmetros usados neste experimento.

2. METODOLOGIA

2.1 Modelo, dados e ambiente

O modelo base foi Qwen/Qwen2.5-3B-Instruct. A execução final ocorreu em Google Colab com GPU NVIDIA A100-SXM4-40GB, Python 3.12.13, PyTorch 2.11.0+cu128, Transformers 4.57.6, PEFT 0.19.1, TRL 0.29.1, Datasets 4.8.5, DeepEval 3.9.9 e bitsandbytes 0.49.2. A seed global foi 42.

O Spider train foi usado apenas para fine-tuning e exemplos few-shot. O Spider dev completo, com 1034 exemplos, foi usado somente para avaliação final. A suíte MMLU contém exatamente 150 questões amostradas de forma determinística de cais/mmlu: college_computer_science, philosophy e econometrics, com 50 questões por categoria. O hash da suíte analisada foi 8fc4621b...

2.2 Prompt e avaliação

No Spider, o prompt de avaliação inclui instrução, esquema do banco-alvo, três exemplos few-shot retirados do Spider train e a pergunta final. O mesmo template foi aplicado ao baseline e a todos os adapters. A geração de avaliação foi determinística: greedy, temperature=0, do_sample=false. No MMLU, o prompt é 5-shot fixo por subcategoria e exige uma única alternativa A, B, C ou D.

2.3 Métrica Execution Accuracy

A métrica customizada ExecutionAccuracy herda de deepeval.metrics.BaseMetric. A saída bruta do modelo passa por extração robusta de SQL: remoção de markdown, localização do primeiro SELECT ou WITH, corte em ponto e vírgula ou marcadores de continuação como Explanation, Schema: e Question:. Consultas não seguras são bloqueadas.

A SQL prevista e a SQL gold são executadas em SQLite em modo read-only, com PRAGMA query_only, timeout e normalização de células. A comparação é insensível à ordem das linhas, exceto quando a consulta contém ORDER BY. A métrica retorna 1,0 se os resultados executados forem equivalentes e 0,0 em erro de sintaxe, erro de execução ou resultado diferente.

2.4 Fine-tuning

O treinamento usou LoRA em BF16, sem quantização, porque a A100 permitiu executar o modelo de 3B com folga após ajuste do microbatch. O dataset de treino foi formatado como prompt + completion, com loss apenas na completion e EOS <|im_end|>, evitando treinar o modelo para copiar o enunciado inteiro. Todas as configurações usaram batch efetivo 16, max_seq_length=2048, adamw_torch_fused, warmup_ratio=0.03, weight_decay=0, TF32 habilitado e group_by_length=true.

Tabela 1. Configurações de LoRA avaliadas.

Exp.	Target modules	LR	Épocas	Batch efetivo	r/alpha/dropout	Train loss	Runtime	Papel na análise
A	q_proj, v_proj	1e-4	1	16	16/32/0,05	0,309	11,0 min	LoRA leve, referência conservadora.
B	q, k, v, o	1e-4	1	16	16/32/0,05	0,260	14,0 min	Isola mais módulos com 1 época.
C	q, k, v, o	1e-4	2	16	16/32/0,05	0,199	28,2 min	Mede segunda época em LR baixo.
D	q, k, v, o	2e-4	1	16	16/32/0,05	0,226	14,2 min	LR maior com 1 época.
E	q_proj, v_proj	1e-4	2	16	16/32/0,05	0,240	21,6 min	Segunda época para LoRA leve.
F	q, k, v, o	2e-4	2	16	16/32/0,05	0,168	27,6 min	Melhor compromisso final.
G	q, k, v, o	1e-4	3	16	16/32/0,05	0,164	41,3 min	Melhor Spider.
H	q, k, v, o	2e-4	3	16	16/32/0,05	0,135	41,7 min	LR maior por 3 épocas.

3. RESULTADOS

A Tabela 2 resume o resultado final. Todos os fine-tuned melhoraram Spider em relação ao modelo base. O ganho absoluto

variou de +6,58 a +9,19 pontos percentuais. No MMLU, as variações foram pequenas: de -3,33 p.p. no Exp A até 0,00 p.p. no Exp F.

Tabela 2. Resultados finais em Spider dev e MMLU 150.

Modelo	Spider EX	Corretas	Delta Spider	MMLU	Corretas	Delta MMLU	Varição relativa MMLU
Base	59,57%	616/1034	0,00 p.p.	57,33%	86/150	0,00 p.p.	0,00%
Exp A	66,92%	692/1034	+7,35 p.p.	54,00%	81/150	-3,33 p.p.	-5,81%
Exp B	66,15%	684/1034	+6,58 p.p.	55,33%	83/150	-2,00 p.p.	-3,49%
Exp C	67,31%	696/1034	+7,74 p.p.	56,00%	84/150	-1,33 p.p.	-2,33%
Exp D	66,92%	692/1034	+7,35 p.p.	56,67%	85/150	-0,67 p.p.	-1,16%
Exp E	66,83%	691/1034	+7,25 p.p.	56,00%	84/150	-1,33 p.p.	-2,33%
Exp F	68,18%	705/1034	+8,61 p.p.	57,33%	86/150	0,00 p.p.	0,00%
Exp G	68,76%	711/1034	+9,19 p.p.	56,67%	85/150	-0,67 p.p.	-1,16%
Exp H	68,57%	709/1034	+8,99 p.p.	56,00%	84/150	-1,33 p.p.	-2,33%

Acurácia final por modelo




Fig. 1. Acurácia final em Spider e MMLU. As linhas pontilhadas indicam o baseline correspondente. A especialização em Spider é consistente; a regressão MMLU é pequena e, no Exp F, nula em acurácia agregada.

3.1 Ganho em Spider

O ganho contra a base é robusto. Em comparação pareada por exemplo, o Exp G corrige 157 casos que a base erra e erra 62 casos que a base acerta, saldo líquido de +95 exemplos. O Exp F tem saldo +89 e o Exp H saldo +93. Em teste binomial pareado sobre discordâncias, todos os LoRAs têm diferença contra a base com p-valor menor que $1e-5$. Esses testes não substituem a análise experimental, mas mostram que o ganho não é explicado por poucas trocas isoladas.

3.2 Regressão em MMLU

O MMLU foi mais estável. O Exp F manteve 86/150, igual à base, embora com trocas internas: ganhou questões em Humanidades e

perdeu algumas em STEM e Sociais. O Exp G perdeu apenas uma questão no total. Como a suite tem 150 questões, uma questão equivale a 0,67 p.p.; portanto, diferenças de 1 a 3 questões entre configs devem ser interpretadas como evidência fraca, não como ranking fino de capacidade geral.

Uma análise da própria suite reforça essa cautela: entre base e oito fine-tuned, 74 questões foram acertadas por todos os modelos e 58 foram erradas por todos. Apenas 18 questões diferenciaram os modelos. Assim, o MMLU 150 atende à especificação do TP e funciona como sanity check de regressão, mas não como uma estimativa completa do MMLU global.




Fig. 2. Trade-off entre ganho Spider e variação MMLU. O quadrante mais desejável é à direita e próximo de zero no eixo vertical. O Exp F é o melhor compromisso; o Exp G maximiza Spider com perda MMLU de apenas uma questão.

4. COMPARAÇÃO DE HIPERPARÂMETROS

A comparação crítica precisa distinguir três níveis: todos os fine-tuned vencem a base; Exp F/G/H formam o grupo mais forte em

Spider; e as diferenças internas entre configs são pequenas. A Tabela 3 mostra comparações pareadas relevantes. O sinal positivo favorece o segundo experimento da comparação.

Tabela 3. Comparações pareadas entre hiperparâmetros em Spider.

Comparação	Pergunta	Saldo pareado	Leitura
A vs B	q/v contra q/k/v/o, 1 época, LR 1e-4	-8 para B	A ficou ligeiramente acima, mas sem evidência forte.
E vs C	q/v contra q/k/v/o, 2 épocas, LR 1e-4	+5 para C	Mais módulos ajudam um pouco em 2 épocas, ainda frágil.
B vs C	1 para 2 épocas, q/k/v/o, LR 1e-4	+12 para C	A segunda época melhorou Spider.
C vs G	2 para 3 épocas, q/k/v/o, LR 1e-4	+15 para G	A terceira época elevou Spider e custou 1 questão MMLU.
D vs F	1 para 2 épocas, q/k/v/o, LR 2e-4	+13 para F	O melhor compromisso veio de 2 épocas com LR maior.
F vs H	2 para 3 épocas, q/k/v/o, LR 2e-4	+4 para H	Ganho Spider mínimo, com queda MMLU de 2 questões.
C vs F	LR 1e-4 contra 2e-4, 2 épocas	+9 para F	LR maior foi melhor no ponto de 2 épocas.
G vs H	LR 1e-4 contra 2e-4, 3 épocas	-2 para H	Em 3 épocas, LR 1e-4 foi ligeiramente superior.




Fig. 3. Efeito de épocas e learning rate. Para q/k/v/o, mais épocas melhoraram Spider. Em LR 2e-4, a terceira época quase não aumentou Spider e reduziu MMLU. Em LR 1e-4, a terceira época produziu o melhor Spider.

O alvo dos módulos não produziu uma conclusão simples. Com 1 época e LR 1e-4, adaptar apenas q/v foi melhor em Spider que adaptar q/k/v/o, mas pior em MMLU. Com 2 épocas e LR 1e-4, q/k/v/o superou levemente q/v em Spider e empatou em MMLU. Portanto, não é correto afirmar que mais módulos sempre melhoram; o efeito depende de época e LR.

O fator mais consistente foi a duração do treino em q/k/v/o. De B para C para G, Spider subiu 66,15%, 67,31% e 68,76%. De D para F para H, subiu 66,92%, 68,18% e 68,57%. Ao mesmo tempo, o MMLU não caiu de forma monotônica: F igualou a base, H perdeu

duas questões e G perdeu uma. A melhor narrativa é que, nestas condições, duas ou três épocas especializam melhor o modelo sem evidência de esquecimento catastrófico forte.

5. ANÁLISE DE ERROS

A análise de erros foi feita principalmente no Exp G, por ser o melhor Spider. A Figura 4 mostra que o fine-tuning reduziu o total de erros e, especialmente, erros de execução. A base teve 163 execution_error; o Exp G teve 95 e o Exp H 76. O principal resíduo passou a ser result_mismatch, isto é, SQL executável mas semanticamente diferente da gold.




Fig. 4. Distribuição de erros Spider. O fine-tuning reduziu o total de falhas e tornou raros os erros de extração de SQL. O ganho principal veio de menos SQLs inválidas ou com colunas/tabelas inexistentes.

5.1 Exemplos qualitativos

Coluna agregada em ordem diferente. Para "How many singers are from each country?", a gold era `SELECT country, count(*) FROM singer GROUP BY country`, enquanto o Exp G gerou `SELECT count(*), country FROM singer GROUP BY country`. A consulta captura a mesma agregação, mas troca a

ordem das colunas, e a métrica por execução compara as tuplas resultantes.

Interpretação incorreta de atributo. Para "What is the maximum capacity and the average of all stadiums?", a gold seleciona `max(capacity), average`. O modelo gerou `max(capacity), avg(average)`. Aqui há execução válida, mas uma decisão

semântica diferente: o campo `average` é tratado como valor a agregar, não como coluna a retornar.

Schema linking imperfeito. Em exemplos do banco `pets_1`, o modelo usou `pet_type`, mas a coluna correta no schema é `pettype`. Esse tipo de erro indica que o fine-tuning melhora o formato SQL, mas ainda falha em detalhes de ligação entre linguagem natural e nomes exatos do banco.

6. DISCUSSÃO

6.1 O ganho justifica a perda geral?

Sim, nas configurações F e G. O Exp F aumentou Spider de 59,57% para 68,18%, ganho de +8,61 p.p., sem queda agregada no MMLU 150. O Exp G aumentou Spider para 68,76%, ganho de +9,19 p.p., perdendo apenas uma questão MMLU. Para a finalidade do TP, isso caracteriza especialização útil com regressão geral pequena. Para uso prático, o Exp F seria a escolha conservadora; o Exp G seria escolhido se a prioridade absoluta fosse Text-to-SQL.

6.2 Fatores que influenciaram o trade-off

O número de épocas e o learning rate tiveram efeito mais visível que a troca isolada de target modules. Aumentar de 1 para 2 épocas em q/k/v/o melhorou Spider tanto em LR 1e-4 quanto em LR 2e-4. A terceira época continuou ajudando em LR 1e-4, mas trouxe retorno marginal em LR 2e-4. O LR 2e-4 foi especialmente forte em 2 épocas, produzindo o Exp F. Já a comparação q/v contra q/k/v/o foi ambígua e não sustenta uma afirmação universal.

A loss de treino caiu com configurações mais longas, mas menor loss não implicou automaticamente melhor generalização. O Exp H teve menor loss, 0,135, mas não foi o melhor em Spider nem em MMLU. Isso é coerente com a hipótese de que, após certo ponto, o treino adicional especializa o formato sem necessariamente melhorar execução no dev.

6.3 Implicações práticas

Para LLMs comerciais especializados, os resultados sugerem que PEFT pode entregar ganhos relevantes em domínio com custo moderado e sem apagar capacidades gerais de forma evidente. Contudo, a decisão de produção não deve usar apenas média agregada. É necessário monitorar regressões por categoria, erros de segurança, SQLs inválidas, drift de formato e robustez em schemas não vistos. A escolha entre F e G ilustra uma decisão real: maximizar a tarefa-alvo ou escolher um ponto mais estável no trade-off.

7. REPRODUTIBILIDADE E AMEAÇAS À VALIDADE

A reprodutibilidade foi controlada por seeds fixas, configs YAML, suíte MMLU persistida, geração determinística e salvamento de métricas, predições, logs e ambiente. O README documenta os comandos para preparar dados, treinar adapters e executar benchmarks. Os resultados deste relatório foram obtidos diretamente dos artefatos em `outputs/`.

Há três ameaças principais à validade. Primeiro, Spider e MMLU são benchmarks públicos, e o modelo base pode ter visto parte desses dados no pré-treino. Isso afeta a interpretação absoluta das acurácias, embora a comparação relativa ainda seja controlada por usar o mesmo pipeline. Segundo, a suíte MMLU tem apenas 150 questões e três subcategorias, como exigido no TP; portanto, ela mede regressão de forma auxiliar, não o MMLU completo. Terceiro, a avaliação por execução é mais fiel que matching textual, mas ainda penaliza diferenças como ordem de colunas quando a saída SQL retorna tuplas com ordem distinta.

8. CONCLUSÃO

O pipeline cumpriu o objetivo do TP: avaliar um baseline, treinar múltiplas configurações LoRA no Spider train, avaliar todos os modelos no Spider dev e no MMLU 150, calcular ganhos e registrar artefatos reproduzíveis. O resultado principal é que LoRA especializou o modelo para Text-to-SQL de forma consistente. O melhor Spider foi o Exp G, com 68,76% de Execution Accuracy,

+9,19 p.p. contra a base. O melhor compromisso foi o Exp F, com 68,18% em Spider e 57,33% em MMLU, igual ao baseline.

A hipótese de regressão de capacidade não foi fortemente confirmada. Houve pequenas perdas em algumas configurações, mas o MMLU variou em poucos exemplos. A conclusão mais imparcial é que, sob estas condições, o fine-tuning LoRA trouxe ganho claro na tarefa-alvo e apenas regressão fraca ou nula na medida geral usada.

REFERÊNCIAS

- [1] T. Yu et al. Spider: A Large-Scale Human-Labeled Dataset for Complex and Cross-Domain Semantic Parsing and Text-to-SQL Task.
- [2] D. Hendrycks et al. Measuring Massive Multitask Language Understanding.
- [3] E. Hu et al. LoRA: Low-Rank Adaptation of Large Language Models.
- [4] Qwen Team. Qwen2.5 model family and model card for Qwen/Qwen2.5-3B-Instruct.
- [5] Hugging Face. TRL, Transformers, PEFT and Datasets documentation.
- [6] Confident AI. DeepEval documentation for custom metrics.